

Support Vector Machines (SVM)

1. Definition

SVM is a powerful and versatile Machine Learning model, capable of performing linear or non-linear classification, regression, and even novelty detection. It is especially strong in classification.

2. Key Concepts

Support Vector

- **Vector:** يشير إلى نقاط البيانات (Data Points).
- **Support:** سميت بذلك لأن أقرب نقاط للخط الفاصل هي التي "تدعمه" وتحدد مكانه (Decision Boundary).
- هي النقاط الوحيدة التي تؤثر في تحديد معادلات الـ Hyperplane، وأي نقطة أخرى (Non-Support Vector) لا تؤثر.

Margin

- Like the widest possible street.
- الهدف هو عمل **Maximize Margin** (توسيع الشارع) ولتحقيق ذلك نحتاج لتصغير الـ Weights (w).
- **Objective:** Minimize $\frac{1}{2} ||w||^2$
- **Condition:** $y_i(w^T x_i + b) \geq 1$.

3. The Intuition

- الفكرة هي العثور على **Optimal Hyperplane** الذي يحقق **Maximum Margin**.
- الهدف من ذلك هو تحقيق أفضل **Generalization** بين الـ Classes وقدرته على التعامل مع بيانات جديدة، وتقليل الـ **Structural Risk**.

4. Types of Margin

A. Hard Margin

- ممنوع أي خطأ تمامًا.
- **عيوبه:** حساس جدًا للـ Outliers (القيم الشاذة).

B. Soft Margin

- ممكن السماح ببعض الأخطاء (الصغيرة).
- نعدل المعادلة بإضافة **Slack Variable** (ζ) وهو يقيس مقدار الخطأ لكل نقطة.

- **New Objective:**

$$\text{Minimize } \frac{1}{2} ||w||^2 + C \sum \zeta_i$$

- **Hyperparameter C:**

- لو قيمته كبيرة: يهتم جدًا بتقليل الأخطاء (Overfitting risk).
- لو قيمته صغيرة: يسمح بتوسيع الشارح وقبول بعض الأخطاء.

5. Mathematical Framework

Objective Function

To increase margin $\rightarrow$ Minimize $\frac{1}{2} ||w||^2$.

Lagrange Multipliers

بنستخدمها عشان عندنا Constraints (قيود) على الـ Function اللي عايزين نصغرها.

1. Primal Form:

- يعتمد على التعامل مع الـ Weights (w) مباشرة.
- المعادلة: $\frac{1}{2} ||w||^2$ subject to constraints.
- Lagrangian: $L(w, b, \alpha) = \frac{1}{2} ||w||^2 - \sum \alpha_i [y_i (w^T x_i + b) - 1]$

2. Dual Form:

- عشان نجيب الحل الأمثل بنفاضل بالنسبة لـ w و b ونساويهم بالصفر.
- المعادلة الناتجة: $w = \sum \alpha_i y_i x_i$
- أهمية الـ Dual:
- الـ Dual أهم من الـ Primal لأن الحل بيعتمد على الـ Dot Product بين النقاط $(x_i \cdot x_j)$.
- ده بيسمح لنا نستخدم الـ Kernels لاستبدال الـ Dot Product العادي في حالات الـ High Dimensions.
- الـ Dual يتعامل مع الـ Support Vectors، عكس الـ Primal اللي بيتعامل مع الـ Features (وده بيكون أمان أكثر).

6. The KKT Conditions (Karush-Kuhn-Tucker)

دي مجموعة شروط لازم تتحقق عشان نضمن إن الحل اللي وصلنا له في الـ Dual هو نفسه الحل في الـ Primal.

- **Complementary Slackness:** (أهم شرط)

$$\alpha_i [y_i (w^T x_i + b) - 1] = 0$$

- عندي احتمالين:

1. $\alpha_i = 0$: يعني النقطة بعيدة عن الهامش (Correctly classified).

2. $y_i(w^T x_i + b) - 1 = 0$: معناه إن النقطة تقع على حدود الهامش بالضبط، ودي هي الـ **Support Vector**.

(وقيم α بتاعتها بتكون أكبر من الصفر).

7. Kernel Trick

بنستخدمه لما تكون الداتا **Non-Linearly Separable** في الـ Input Space.

أنواعها:

1. **Polynomial Kernel**: Active Relation عشان تعمل بين الـ Features.
2. **RBF Kernel (Gaussian)**:

- يعتمد على المسافة بين النقاط.
- يتحكم فيه الـ **Gamma (γ)**: وده بيحدد مدى تأثير نقطة واحدة (Influence Radius).

8. Implementation Notes

- **LinearSVC**:

- يعتمد على حل الـ **Primal Problem**.
- فعال وممكن يكون أسرع للداتا الكبيرة خطياً.

- **SVC**:

- يعتمد على الـ **Dual Problem** وده الأنسب لما نستخدم **Kernels**.
- لكن تعقيده الحسابي (Computational Complexity) بيزيد مع عدد العينات: $O(m^2 \cdot n)$ إلى $O(m^3 \cdot n)$.

- **Feature Scaling**:

- ضروري جداً لأن الـ SVM يعتمد على الـ **Euclidean Distance**.